

بجای ها، آمار و نمایه های نویسنده را برای این نشریه در: <https://www.researchgate.net/publication/354362447> ببینید

## تشخیص بیماری های گیاهی مبتنی بر تصویر با استفاده از یادگیری عمیق

مجموعه مقالات پژوهش در مواد امروز ژوئیه 2021

DOI: 10.1016/j.matpr.2021.07.281

نقل قول ها

157

می خواند

7,078

6 نویسنده، از جمله:



پانکاج کومار

دانشگاه بابو بناراسی داس

8 tPUBLICATIONS t257 tCITATIONS

نمایه را ببینید



دانشگاه Muke

sh Sonin Chandigarh

261 tPUBLICATIONS t3,872 tCITATIONS

نمایه را ببینید



لیست محتوا در ScienceDirect قابل دسترسی است

## مواد امروز: مجموعه مقالات

صفحه اصلی مجله: [www.elsevier.com/locate/matpr](http://www.elsevier.com/locate/matpr)

## تشخیص بیماری های گیاهی مبتنی بر تصویر با استفاده از یادگیری عمیق

Adesh V. Panchalt at, Subhash Chandra Patel t bt, K. Bagyalakshmit ct, Pankaj Kumart dt, Ihtiram Raza Khant et, nMu kesh Sonit ft, t

ا گروه علوم و مهندسی کامپیوتر، GEC Patan، هند  
 ب دانشکده علوم و مهندسی کامپیوتر، دانشگاه VIT بوپال، سهور، بوپال، MP، هند  
 ح مهندسی برق و الکترونیک، موسسه مهندسی و فناوری SRI Ranganathar، Coimbatore، هند  
 د گروه علوم و مهندسی کامپیوتر، موسسه مهندسی و فناوری، نویدا بزرگ، اوتار پرداس، هند  
 و جامیا همدر، گروه علوم کامپیوتر، دهلی، هند  
 f دانشگاه جاگران لیک سیتی، بوپال، هند

## اطلاعات مقاله

## چکیده

تاریخچه مقاله:  
 XXXX آنلاین موجود است

کلمات کلیدی:  
 CNN  
 بیماری زراعی د  
 رکشاوری

کشاورزی نقش مهمی در کشورهای در حال توسعه مانند هند ایفا می کند، با این حال امنیت غذایی همچنان یک موضوع حیاتی است. بیشتر محصولات به دلیل کمبود انبار، حمل و نقل و بیماری های گیاهی تلف می شوند. بیش از 15 درصد از محصولات در هند به دلیل بیماری ها هدر می رود و از این رو به یکی از نگرانی های اصلی تبدیل شده است. نیاز به سیستم اتوماتیکی وجود دارد که بتواند این بیماری ها را شناسایی کند و کشاورزان را در انجام اقدامات مناسب برای رهایی از ریزش محصول یاری دهد. کشاورزان از روش مرسوم شناسایی بیماری گیاهی با چشم غیر مسلح پیروی می کنند و تشخیص این بیماری ها برای همه کشاورزان یکسان ممکن نیست. با پیشرفت در هوش مصنوعی، نیاز به گنجاندن امکانات بیابایی کامپیوتر در حوزه کشاورزی احساس می شود. کتابخانه های غنی از یادگیری عمیق و کاربر و همچنین محیطی مناسب برای توسعه دهندگان، ه مه این ویژگی ها یادگیری عمیق را به عنوان روشی مناسب برای شروع با این مشکل تبدیل می کند. در این مقاله ما از یادگیری عمیق به دلیل مزایایی که برای کار با تصاویر به ویژه در طبقه بندی تصاویر برای به دست آوردن نتایج پداهه ارائه می دهد، استفاده کرده ایم. سپس روش شناسی شامل گرفتن برک های محصولات آلوده و برچسب گذاری بر اساس الگوی بیماری است. سپس تصاویر برک های آلوده پردازش می شوند، عملیات مبتنی بر پیکسل برای بهبود اطلاعات از تصویر اعمال می شود. به عنوان مرحله بعدی استخراج ویژگی به دنبال تقسیم بندی تصویر و در آخرین طبقه بندی بیماری های محصول بر اساس الگوهای استخراج شده از برک های بیمار انجام می شود. از CNN (شبکه عصبی کانولوشنال) برای طبقه بندی بیماری ها استفاده می شود، برای هدف نما پس از مجموعه داده عمومی شامل حدود 87 تصویر K (تصاویر نوع RGB شامل برک های سالم و یا برک های بیمار استفاده می شود.

© 2021 Elsevier Ltd. کلیه حقوق محفوظ است.

انتخاب و بررسی توسط کمیته علمی کنفرانس بین المللی نانو الکترونیک، نانوفوتونیک، نانو مواد، نانوبیوسینس و نانوتکنولوژی. تمام حقوق محفوظ است.

## 1. معرفی

شناسایی بیماری های گیاهی بر اساس تصویر، موضوعی است که اخیراً توسط بسیار ی از محققان مورد بررسی قرار گرفته است. با افزایش صنایع محصولات کشاورزی به دلیل بیماری ها، شناسایی دقیق و به موقع بیماری ها بسیار مهم شده است. در کشورها ی در حال توسعه، به ویژه در جنوب آسیا، بیشتر جمعیت به طور مستقیم یا غیرمستقیم به کشاورزی وابسته هستند، بنابراین استفاده از برنامه شناسایی بیماری های گیاهی می تواند به کشاورزان کمک کند تا علت بیماری ها را بشناسند و برای درمان آن ها اقدام کنند.

شناسایی اولیه بیماری های گیاهی بر اساس اندازه برک، رنگ برک و رشد الگو و غیر ه می تواند به کشاورزان کمک کند.

با افزایش استفاده از تلفن های هوشمند در سراسر جهان، گرفتن تصویر برک ها بسیار آسان شده است، همچنین بسیاری از مردم در سراسر جهان به امکانات این ترنت پایه دسترسی دارند. بیش از 300 میلیون نفر به اینترنت دسترسی دارند و از برنامه های مختلف استفاده می کنند. دولت ها امکانات مختلفی مانند شماره های خط کمک 24\*7 اختصاص داده شده به کشاورزان برای حل سوالات آن ها ارائه داده اند، اما مردم ساکن مناطق روستایی به سختی می توانند به امکانات مناسب دسترسی پیدا کنند.

↑ نویسنده اصلی.

آدرس ایمیل: soni.mukesh15@gmail.com (M. Soni)

<https://doi.org/10.1016/j.matpr.2021.07.281>

2214-7853/ © 2021 Elsevier Ltd. All rights reserved.

انتخاب و بررسی توسط کمیته علمی کنفرانس بین المللی نانو الکترونیک، نانوفوتونیک، نانو مواد، نانوبیوسینس و نانوتکنولوژی. تمام حقوق محفوظ.

بنابراین برای یافتن راه حلی برای مشکلات خود تلاش می کنند. یک برنامه اساسی که در آن کشاورزان می توانند به سادگی بر روی شناسایی بیماری مبتنی بر تصویر خود گام کار کنند، مفید خواهد بود.

بیماری محصولات زراعی در حال تبدیل شدن به یک تهدید جهانی است و نیاز به توجه محققان دارد، استفاده از آفت کش ها و حشره کش ها ممکن است راه حل موقتی باشد اما ممکن است برای طولانی مدت مفید نباشد. همچنین پس از آن مواد شیمیایی اثرات جانبی بر محصول می گذارند که در نهایت می تواند بر سلام ت شهروندان اثر سوء داشته باشد. در سناریوی کنونی، زمانی که کاربردهای هوش مصنوعی در بسیاری از مناطق متقابل دامنه گسترش یافته است، کمک گرفتن از هوش مصنوعی برای حل مشکلات کشاورزی مفید خواهد بود. اگرچه تعداد محصول لات و بیماری ها از نظر تعداد بسیار زیاد است، اما شروع با شناسایی بیماری های محصولات غیر معمولی که در هند استفاده می شود، شروع معقولی خواهد بود.

این مقاله مفهوم طبقه بندی تصویر را برای شناسایی بیماری ها با کمک ویژگی ها ی ارائه شده توسط بینایی کامپیوتر مورد بحث قرار می دهد. بسیاری از کارهای مرتبط [1,2] روی شناسایی شی با استفاده از یادگیری عمیق انجام شده است که ادعا می کند نتایج بداهه ای را شناسایی می کند، استفاده از این مدل از قبل موجود به سیستم ما کمک می کند تا دقت بهتری داشته باشد و از این ر و ما از یادگیری عمیق برای هدف پیاده سازی خود استفاده کرده ایم. ما از شبکه عصبی عمیق برای پردازش تصاویری که به عنوان ورودی (تصویربرداری گیاهان بیمار گرفته می شود، استفاده کرده ایم و جفت خروجی را دریافت می کنیم که با بیمار ی موجود در گیاه نقشه برداری می کند. شبکه عصبی عمیق شامل شبکه های عصبی متعددی است که از مدل ریاضی برای پردازش ورودی استفاده می کنند. لایه ها در هر سطح دارای پیکربندی متفاوتی هستند که با توجه به داده های ورودی تن طیم می شود و داده ها از همه این شبکه ها عبور می کنند و داده ها را در هر لایه ا صلاح و پاک می کنند و خروجی را از آخرین سطح دریافت می کنند. وظیفه اصلی تصمیم گیری در مورد ویژگی هر لایه و اندازه شبکه به همراه مدل مورد استفاده است. تنظیم پارامترهای شبکه در مرحله آموزش به منظور بهبود فرآیند آموزش و به دست آوردن نتایج نهایی دقیق انجام می شود. مدل اصلی یادگیری عمیق مورد استفاده در این مقاله از شبکه های عصبی کانولوشن (CNN) کمک می کند، این یک ی از تکنیک های قدرتمند در حین کار با حجم عظیمی از داده است و همچنین یکی از محبوب ترین تکنیک ها برای تشخیص الگو است. از آنجایی که کار بر ورودی تص ویر تمرکز دارد، CNN نسبت به مدل های دیگر ارجحیت دارد.

برای ایجاد یک مدل بهتر برای طبقه بندی بیماری گیاهی، داشتن مجموعه داده های غنی به منظور آموزش مدل مهم است. در این مقاله از مجموعه داده های ده کده گیاهی استفاده شده است  
با 50,000 تصویر. در اینجا ما به 38  
تعداد بیماری ها در 14 نوع از محصولات کشاورزی. بر اساس عملکرد مدل، دقت 90.4%، نتایج قابل توجه هستند و بهترین نتیجه را از سیستم های موجود است فاده از روش تصویرباز برای شناسایی بیماری های گیاهی ارائه می دهند.

## 2. بررسی کارهای مرتبط/بررسی ادبیات

محققان راه های مختلفی را برای شناسایی بیماری های گیاهی بررسی کرده اند. با این حال، ما هنوز راه درازی در پیس داریم تا به سیستم خودکار برسیم که استفا ده از آن را آسان کند و این مشکل را مدیریت کند. استفاده از تکنولوژی های کامپیو تری برای شناسایی بیماری های محصولات کشاورزی در سطح های مختلف مورد بررسی قرار گرفته است. نویسندگان در [3] Lee et al. از نمایندگی های نیمه نظار تی برای ۴۴ گونه گیاهی استفاده کرده اند و مدل CNN را به کار برده اند و از تکنیک های تصویرسازی مبتنی بر شبکه های بازگشتی (DN) استفاده کرده اند. بر اساس [4]، روش های مبتنی بر تکنیک های یادگیری ماشین تحت برخی محدودیت ها و محدودیت ها نسبتاً موفق هستند و بسیاری از مشکلات هنوز حل نشده اند تا به اجر ای موفق این روش ها در دنیای واقعی برسیم. مقاله همچنین عوامل تأثیرگذار بر استفاده از تکنیک های یادگیری عمیق برای تشخیص بیماری های گیاهی را ذکر کرد ه است که شامل فقدان مجموعه های داده برچسب گذاری شده، شناسایی علائم، پیدا کردن تقسیم دقیق داده های آموزشی و تستی در مدل، کیفیت تصاویر، شرا یط ضبط تصاویر، ناهمزمانی چندین اختلال و اختلال مشابه است.

علائم. Barbedo [5] روی روش تقسیم تصویر کار کرده است تا بیماری های گیاهی را در پس زمینه سیاه و سفید شناسایی کند و سعی کند خطاهای انسانی را کاهش دهد در حالی که زمان کمتری برای شناسایی این بیماری ها صرف می شود. اما پی شهاد می کند که خطاهای ناشی از اشتباه در طبقه بندی پیکسل ها را کاهش دهد و مجموعه ای غنی از داده های برچسب گذاری شده که به تأیید دقیق مدل کمک م ی کند، به دست آورد.

بسیاری از مقالات [6,7] در زمینه شناسایی بیماری های گیاهی بر اساس تصو یر، روش های پایه ای برای پیس پردازش را دنبال می کنند که شامل حذف پس زم ینه و تقسیم بافت آسیب دیده گیاه بیمار است. در مرحله بعد، ویژگی های تسخی صی استخراج می شوند تا به تحلیل بیشتر بیماری گیاه پردازند و سپس مدلی برای طبقه بندی بیماری ها ایجاد می شود. در کار آل-هیری و همکاران [6]، نویسندگان پیکسل های سبز را شناسایی کرده و این پیکسل ها را بر اساس یک مقادیر محدود ه خاص ماسک گذاری کرده اند. آن ها دقت بین 83% تا 94% به دست آورده اند. برخی از محققان بر روی گیاهان خاص برای شناسایی بیماری ها کار کرده اند، مانند در کار مختار و همکاران [7]، نویسندگان بر روی شناسایی دو بیماری به نام های ویر وس چروک برک زرد گوجه فرنگی (TYLCV) و بیماری چروک برک زرد گوجه فرنگی (T YLCD) در گیاه گوجه فرنگی با استفاده از برک های گوجه فرنگی کار کرده اند. آن ها از تکنیک نحوه ی ارزیابی چندگانه (N-fold cross-validation) به عنوان مدل خود استفاده کرده و میانگین دقت 90% را به دست آورده اند. کارها ی قبلی در طبقه بندی بیماری های گیاهی از روش های یادگیری ماشین سنتی برای انجام کار خود در کار آریوازاهاگان و همکاران استفاده کرده اند. نویسندگان در مورد تشخیص ناحیه های ناسالم برک گیاهان بحث کرده اند، آنها از معیار فاصله کم تری ن و طبقه بندی کننده SVM با استفاده از ویژگی های بافت برای بیماری های برک گیاهان استفاده کرده اند.

تعیین پارامترهای طبقه بندی یک چالش بزرگ است، در کار Tian et al [9] از الگوریتم ژنتیک برای انتخاب پارامترهای ماشین بردار پشتیبان (SVM) استفاده شد ه است. ترکیبی از تحلیل اصلی اجزا هسته ای (KPCA/مدل GA-SVM) استفاده شده است.

آنها بیماری های گیاهان سبب را طبقه بندی کرده اند و ادعا می کنند که دقت بی س از 95% را در سه بیماری مختلف به دست آورده اند [10]. در این مقاله، نویس ندگان بر روی مدل Machine Learning مبتنی بر هسته های هسته ای برای طبق ه بندی بیماری ها تکیه کرده اند و با استفاده از هسته چندجمله ای و حاشیه نرم، د قت 95% به دست آورده اند. در [11] Krizhevsky et al. نویسندگان شبکه های عمیق متمرکز بر تبدیل تصویر برای طبقه بندی بیماری ها در 1000 کلاس مختلف با استفاده از مجموعه آموزشی Image Net 2010 LSVRC آموزش داده اند. آنها ا ز شبکه های بسیار چگال با 60 میلیون پارامتر و 500,000 نورون استفاده کرده اند. در [12] Ferentinos et al. نیز مدل شبکه های متمرکز بر تبدیل تصویر برای تس خیس بیماری های گیاهی توسعه داده شده و نتایج شامل 58 کلاس متمایز از ترکی ب [گیاه، بیماری] بود. نتایج این کلاس ها 99.53% بود و برای استفاده در تسخی ص زودرس بیماری های گیاهی در زمان واقعی توصیه شد. برخی از محققان روش های مختلفی [13-22] برای تشخیص بیماری های تصویری و استفاده از دستگاه ه ای IoT برای استخراج داده ها پیشنهاد کرده اند. همچنین محققان پروتکل های مخ تلفی در زمینه بهداشت [23-28] و ارتباطات خودرو [29-35] پیشنهاد می دهند تا از اطلاعات تبادل شده بین دستگاه های مختلف محافظت شود.

## 2.1. اجرا

چون ما یک مجموعه داده تصویر داریم و مشکل ما پیدا کردن تصاویر معیوب ا ز این مدل یادگیری عمیق است که بهترین مدل برای حل مدل ماست. زیرا یادگیر ی عمیق مربوط به یادگیری ساختاری است و با توجه به اینکه تعداد داده های آموز شی ما کمتر است.

ما چندین مدل داریم، به عنوان مثال، ساخت یک شبکه ساده از ابتدا و یادگیری انتقال با تنظیم دقیق ترین لایه های شبکه عصبی عمیق که قبلاً آموزش دیده اس ت.

شبکه های ساده تنها چند لایه ی فیلتر با تعداد کمی فیلتر در هر لایه دارند، س پس چند لایه ی متصل به طور کامل بین شان وجود دارند و در نهایت استفاده از تنظیم کننده ی عادی شده است. سپس آموزش شبکه های ساده با تعداد 2، 4، 6، 8 و 10 لایه ی فیلتر. ما لایه های فیلتر با اندازه 3x3 و فعال سازی مانند خط مس تقیم داریم.

واحد گوسٹ (ReLU)، و هر لایه دارای لایه حداکثر پوئلیک اندازه  $2 \times 2$  می باشد، به استثنای لایه نهایی فیلترهای کانولیش که 64 فیلتر دارند. ابتدا، همه لایه هایی که به طور کامل متصل هستند، دارای فعال سازی ReLU با 6 واحد در آن ها هستند و سپس با نسبت 50% dropout در لایه dropout ادامه می یابد. در تطابق با 4 طبقه، لایه آخر که نیز به طور کامل متصل است، دقیقاً خروجی دارد. که به عنوان ورودی به لایه بعدی تبدیل می شوند تا احتمال خروجی م حاسبه شود.

با توجه به اینکه تعداد کمتری از تصاویر آموزشی برای یادگیری داریم، یادگیری انتقالی نقش حیاتی دارد تا شبکه ای دقیق برای طبقه بندی ایجاد شود، از طریق استفاده از مقدار کمی داده های موجود، با تنظیم مناسب پارامترهای شبکه ای که قبلاً بر روی مجموعه داده بزرگی مانند Image Net آموزش دیده است. از آنجا که شدت سطح بیماری هدف برای تنظیم یک مجموعه تصاویر مناسب برای مسئله طبقه بندی تصاویر در مقایسه با Image Net است، لایه های پایینی تنها ویژگی های پایه را استخراج می کنند که می توان آن ها را به یک گروه بزرگتر از مشکلات بینا یی رایانه ای گسترش داد. مانند، لایه اول که تنها شدت رنگ و جهت را نشان می دهد و در تصویر 1، فعال سازی لایه اول مدل VGG16 نشان داده شده است. به دل یل اینکه بدون آموزش بر روی مجموعه داده های موجود خود، این معماری

توسط نقطه های بیماری ها فعال می شود، همچنین در برگ و

در پس زمینه.

برای یادگیری انتقال، ما چندین مقایسه داریم مانند، ResNet [36]، VGGNet [50] [36]، Inception-v3 [37]، مدل های CNN دارای 16 VGG16 (و VGG19) لایه وزنی است که با استفاده از مدل هایی با تغییرات کوچک در فرآیند فیلتراسیون، پیشرفت معناداری نسبت به مدل های موجود به دست می آورد.

مدل پایه Inception مدل GoogleNet به روشی که شامل شبکه های تو در تو و استفاده از فیلترهای اندازه های مختلف برای مدیریت مقیاس های متعدد است، می پیوندد. مدل موجود Inception-v3 یک مدل بهبود یافته با کارایی بیشتر است و می تواند با تعداد کمی پارامتر بهبود یابد. ResNet از قرار دادن یک بلوک بر روی دیگری و باقی مانده بلوک های بنیادی ساخته شده است. این بلوک های بنیادی از چندین لایه ی فیلترکواریانس تشکیل شده اند که با اتصالات گسترده یا بدون اتصالات در برخی از بلوک ها هستند. این امکان را می دهد که تمام لایه های روی هم قرار گرفته در یک نقشه ی باقی مانده قرار گیرند، در حالی که اتصالات پرسش دارای نقشه ی شناسایی هستند. بنابراین، وظیفه ی ما به ساده تر کردن تعداد فیلترهای باقی مانده تبدیل می شود تا اینکه تعداد فیلتر اصلی را کاهش دهیم. این مدل مس کل شکستن را حل می کند: با قرار دادن چندین لایه بر روی یکدیگر، کارایی در نقطه ای متوقف می شود و سپس به صورت نمایی کاهش می یابد.

ResNet50 نسخه 50 لایه این شبکه است.

## 2.2. مواد و آزمایش

**DataSet:** ما از مجموعه داده های Plant Village استفاده می کنیم که یک مجموعه داده دسترسی آزاد است و در Kaggle موجود است [38]. مجموعه داده های Plant Village شامل حدود 50,000 تصویر از محصولات کشاورزی کاملاً سالم و بیمار است که در 38 دسته برچسب گذاری شده اند. نگرانی ما در انتخاب تصاویر ورودی برگ های کاملاً سالم سیب و تصاویر ورودی دارای بیماری سیاه برگ تح ت تأثیر قارچ به نام


*Botryosphaeriaobtusa* است. هر تصویر ورودی به دسته مناسب خود توسط متخصص حوزه، یعنی گیاه شناسان، قرار می گیرد: مرحله اولیه سالم، مرحله میانی سالم، مرحله سالم یا در مرحله کاملاً سالم. در مرحله کاملاً سالم، هیچ لکه ای در برگ ها وجود ندارد. برگ های سالم مرحله اولیه دارای لکه های دایره ای کوچک با قطر حدود 2.5 میلی متر هستند. برگ های سالم مرحله میانی دارای لکه های بیشتری هستند که به شکل تصادفی یا سطحی رشد می کنند. برگ های سالم مرحله آخر که به میزان بیشتری توسط درخت آلوده شده اند و نمی توانند در درخت باقی بمانند. تمام تصاویر ورودی توسط متخصصان حوزه بررسی شده و با برچسب گذاری به ی ک بیماری مناسب طبقه بندی شده اند.

180 تصویر که توسط متخصصان طبقه بندی دشوار بود از بررسی های بعدی حذف شدند. در تصویر مثال هر مرحله نشان داده شده است. در نهایت، ما 1650 تصاویر ورودی از برگ های کاملاً سالم، 130 مرحله اولیه سالم، 175 مرحله میانی سالم و 130 مرحله آخر بیمار سالم داریم.

چون تعداد برگ های سالم ما از برگ های بیمار بیشتر است، ما تغییرات زیادی در تعداد نمونه ها برای هر دسته داریم. برای کاهش احتمال تورم در شبکه ما تا تعداد بیشتری از دسته های سالم مرحله سالم داشته باشیم، تعداد نمونه ها برای هر دسته باید متوازن باشد. برای ایجاد توازن مناسب، ما استراتژی زیر را داریم: در مرحله اولیه سالم، مرحله میانی سالم و مرحله آخر سالم، ما استراتژی تقسیم 20-80 بین آم وزن و تست داریم که به این معناست که حدود 80% از تصاویر ورودی برای مجموعه آموزشی حفظ می شوند و تصاویر باقی مانده برای مجموعه تست. برای برگ های مرحله سالم، تصاویر به 12 دسته طبقه بندی می شوند، با 120 تصویر در هر دسته برای مجموعه آموزشی، حدود 30 تصویر برای تست حفظ می شود. دقت نه ایی با میانگین 12 اجرای مختلف بر روی دسته ها محاسبه می شود. همانطور که می دانیم، مجموعه داده های Plant Village تصاویری از همان برگ از زوایای مختلف و جهت های مختلف گرفته شده است، تقریباً تمام تصاویر همان برگ باید یا در مجموعه آموزشی یا در مجموعه تست حفظ شوند.

**جدول 1** تعداد تصاویر استفاده شده برای آموزش و تست برای هر دسته را نشان می دهد.

پیش پردازش: نمونه های مجموعه داده های Plant Village تصاویر RGB اندازه ه متفاوتی دارند. با استفاده از یادگیری عمیق پایه، ما تنها نیاز به 4 تصویر در مرحله اولیه که مرحله پیش پردازش است داریم.



تصویر 1. در مدلی که قبلاً آموزش دیده است، نمایش لایه های شروع فیلترهای ضربی برای یک تصویر ورودی خاص. منبع داده: (b) خروجی لایه شروع فیلترهای ضربی.



## جدول 1

مجموع نمونه های مجموعه های آموزشی و آزمایشی.

تصاویر کل برای تست	مجموع تصاویر برای آموزش	طبقه
مرحله 27	110 12	مرحله سالم
مر	108	اولیه سالم
36	144	حله میانی سلامتی
23	102	مرحله سالمی به پایان رسید

این کار در مراحل مختلف به صورت زیر انجام می شود: ابتدا، تغییر اندازه تصویر و دی به  $256 \times 256$  پیکسل برای شبکه های ساده،  $224 \times 224$  با تمام مدل هایی که تا کنون استفاده کرده ایم، در  $299 \times 299$  Inception-V3 پیکسل. در فرآیند تغییر مقیاس تصاویر، پیس یینی و بهینه سازی مناسب اعمال شده است. سپس، تقسیم 255 بر روی مقادیر پیکسل انجام می شود که قابل محاسبه با مقدار شروع شبکه ما است. سپس نرمال سازی برای هر یک از نمونه ها انجام شد. که در واقع عملکرد تمرین را به طور قابل توجهی افزایش می دهد. سپس فرآیند نرم ال سازی مراحل زیر را طی می کند: برای همه داده های آموزشی، پس از محاسبه م یانگین و S.D، تبدیل داده های آموزشی در مجموع  $X = (X_{Mtx})/Stxt$  انجام شده است، به طوری که هر ویژگی تقریباً به یک داده نرمال شده نگاه می کند که به میان گین 0 و واریانس 1 توزیع شده است. در پایان، برخی از عملیات مانند چرخش با زا ایای مختلف، برش، زوم کردن، و چرخش برای ورودی های داده شده استفاده می شود. این امر عدم اتصال را تضمین می کند و مدل را برای استفاده مناسب می سازد.

الگوریتم آموزشی مدل اولیه (CNN) شبکه عصبی پیچیدگی (از لایه های پیچیدگی، لایه های ادغام و در آخر لایه های کاملاً متصل تشکیل شده است.

در لایه کانولوشن برای هر تصویر ورودی، محاسبه  $X_{tit}$  به صورت زیر انجام نمی شود

$$X_{ic} = RELU(W_i * X) \quad (1)$$

در اینجا عمل کانولوشن با  $t$  نشان داده شده است و  $W_{tit}$  مخفف هسته های لایه پیچیدگی است.  $W_{tit} = [W_{tit1}, W_{tit2}, W_{tit3}, t, \dots, t, nW_{tit}]$  و  $K$  نشان دهنده تعداد کل هسته های پیچشی است.

از آنجایی که ما اشباع غیر خطی در تصویر خود داریم، بهترین انتخاب تابع غیرفع ال سازی باید ReLU باشد، زیرا زمان بسیار بیشتری نسبت به سایر توابع فعال ساز ی موجود است. ReLU یک تابع فعال سازی خطی اصلاح شده به شرح زیر است:

$$ReLU(x) = \max(0, x)$$

بنابراین در مدل ما از ReLU استفاده خواهیم کرد. همانطور که در لایه max pooling باید بزرگترین val-nue خروجی همه لایه ها ی پیچشی را که یکدیگر را قطع نمی کنند محاسبه کنیم. این تکنیک رتبه های متقا وی را در محیط های موجود تعیین می کند و اندازه خروجی ما را بهینه می کند.

نقش لایه ی کاملاً متصل شده این است که لایه ی نهایی را در بالاترین سطح نگه دارد. سپس همه لایه های  $c$  این چینی که در بالای همه قرار دارند، محاسبه  $ReLU(Wfc \cdot X)$  را انجام می دهند، جایی که  $X$  نشان دهنده تصویری است که باید داده شود و  $Wfc$  نشان دهنده ماتریس وزن نهایی لایه است. تابع زیان تغییر نتیجه با ورودی را محاسبه می کند، که توسط متخصص حوزه د اده شده است و به عنوان مجموعه ای از انتهای خروجی تعریف شده است.

اگر شبکه ما با سرعت بسیار بالا شروع به آموزش کند و در ابتدا خودش دقت بسیار بالایی داشته باشد، باید آن را متوقف کنیم زیرا این مشکل اضافه پیس یینی است. برای این منظور از تکنیک توقف زودرس استفاده می کنیم. در این روش ب س از هر دوره، عملکرد با داده های آموزشی موجود ارزیابی می شود و وقتی که زیان داده های مجموعه تست به خود بهبود نمی یابد، توقف زودرس آموزش شبکه را متوقف می کند.

این روش اضافه پیس یینی را حل می کند؛ ما یادگیری انتقال را به صورت زیر انجا م می دهیم:

همه لایه های نهایی با کمک ایجاد یک لایه دیگر و توجه به این که فقط لایه های خارجی فیلتر کانولوشن VGG19 با VGG16 با لایه های متصل نهایی به هم متصل می شوند، جایگزین می شوند.

وزن های آموزش دیده شده را حذف کنید تا از وجود گرادیان جدید اطمینان حاصل شود، بنابراین شبکه موجود باید با مقادیر مناسب شروع کند به جای تنظیم هر پارام تری. حالا به جز شبکه اخیر، همه لایه ها را در شبکه قرار دهید. در نهایت، آموزش لایه متصل به کمک ویژگی های تولید شده در لایه کانولوشن نهایی انجام می شود. پس از تنظیم پارامترها، یادگیری وزن یا تنظیم آن انجام می شود. سپس لایه کانولو سن نهایی برای همه معماری هایی که در شبکه ما استفاده شده اند با آموزش مواز ی و نرخ یادگیری کمی پایین تر ادامه می یابد.

در جدول 2، جزئیات تنظیم پارامتر مدل آموزش دیده نشان داده شده است. ع لاه بر این، برنامه زمانی نرخ یادگیری استفاده شده است. تغییرات نرخ یادگیری در جدول نشان داده شده است.

## 3. نتایج و بحث

دقت شبکه ساده ما در شکل 2 نشان داده شده است. با عمق مدل ما، در اب تدا هم دقت آموزش و هم دقت تست به طور کمی بهبود می یابد. بهترین نتیجه، که یک دقت اعتبارسنجی 81.4% است، توسط شبکه ما با 10 لایه کانولوشن که د ر تنظیم پارامتر به دست آمد، به دست آمد.

اما این کاهش یافت پس از اینکه عمق شبکه از 10 بیشتر شد، زیرا داده هایی که د اریم برای مدل هایی که این مقدار از پارامترها را دارند کافی نیستند. برای حل این م سکل، ما یادگیری انتقال را در مدل های عمیق جدید به کار برده ایم.

نتایج تنظیم پارامتر مدل های Image Net در شکل 2 نشان داده شده است. دقت نهایی مجموعه های موجود برای تأیید از 84.0% تا 93.5% متغیر است. دق تی که پس از تنظیم پارامتر به دست آمده است، بهتر از مدل موجودی است که ق بلا آموزش دیده است.

مهم ترین نتیجه در مدل VGG16 جشن گرفته شده است، که دقت 93.5% دارد. نتایج ما نشان می دهد که حتی اگر داده های کافی نداشته باشیم، یادگیری انتقال م ی تواند نتایج بهتری ارائه دهد.

در مطالعه مقایسه ای، مدل شبکه عصبی مصنوعی ما از بهینه کننده ی کاهسش گام تصادفی در داده های آموزشی موجود برای همه ی لایه ها استفاده می کند. با ا ستفاده از حدس تصادفی، 37% دقت در مجموعه ی تأیید به دست آمده است. ا گر در نوار فیلتراسیون ویژگی یابی نباشد، ANN قادر به یافتن روابط محلی نیست و همچنین نمی تواند ویژگی ها را با استفاده از داده های موجود تشخیص دهد.

ماتریس تشخیص مدل های ما در جدول 2 نشان داده شده است. بخشی از د قت تأیید پیس یینی شده برای همه ی تصاویر همه ی مراحل با جزئیات کامل نشا ن داده شده است. طبقه بندی همه ی برگ های مرحله ی سالم دقیق انجام شده ا ست.

دقت مرحله ی اولیه و نهایی به ترتیب 93.5% و 87.2% است. دقت مرحله ی میانی امیدوار است به درستی طبقه بندی نشود، با دقت به دست آمده 80.4%. ا ما همه ی مراحل که به درستی طبقه بندی نشده اند با مراحل بعدی اشتباه گرفته م ی شوند. به عنوان مثال، مرحله ی اولیه با مرحله ی میانی تنها اشتباه گرفته می شود و هیچ یک از مرحله ی اولیه با مرحله ی نهایی اشتباه گرفته نمی شود.

یافته های ما نشان می دهد که توجه به این نکته مهم است که تقریباً 100% د قت آموزش ممکن است، که مطلوب نیست و می تواند با توقف زودرس جلوگیری ی شود. اما همانطور که می دانیم که یادگیری عمیق داده محور است، اگر داده ها ی آموزشی بیشتری داشته باشیم تا دقت تأیید را بهبود بخشیم، خوب است. در ا ینجا می توانیم توجه کنیم که VGGNet


## جدول 2

استفاده از یادگیری انتقال، ماتریس گچی برای تأیید مدل VGG16.

مطمن شده شده			
پایان مرحله سالم	مرحله م یانی سالم	مرحله ی زودرس و سالم	مرحله سالم
م	0	0	مرحله سالم
م	2	27	رحله اولیه
م	30	5	رحله میانی
20	3	0	رحله آخر




(a) healthy stage



(b) early healthy stage



(c) middle healthy stage



شکل 2. برای سیب سیاه روت، نمونه های تصاویر برگ در همه مراحل: a) مرحله سالم، b) مرحله اولیه سالم، c) مرحله میانی سالم و d) مرحله انتهایی سالم.

مدل به بهترین عملکرد دست یافته که مشابه [39,40] نیز است، در آن وظیفه ش ناسایی گیاه با بهترین عملکرد توسط مدل VGGNet انجام می شود. عملکرد مدل های دیگر مانند

ResNet برای انجام وظایف طبقه بندی ما به اندازه VGGNet خوب ن یست، حتی اگر بهترین نتیجه در مجموعه داده Image Net ثبت شده باشد.

## نتیجه گیری و دامنه آینده

تحقیق ما مدل یادگیری عمیقی را ایجاد کرده است که قابلیت کشف ویژگی‌ها ی معنادار در وظیفه طبقه بندی به صورت خودکار دارد، که در واقع یک راهنمای کامل برای تشخیص جدیت بیماری را فراهم می‌کند. با داشتن تعداد کمی داده ورودی، ما در ابتدا یک شبکه ساده ای با اندازه کوچک تر و تعداد لایه های متغیر آموزش دادیم و پارامترهای چهار مدل اخیر را کاملاً تنظیم کردیم: Inception-v3, ResNe t50, VGG16 و VGG19.

با انجام مطالعه مقایسه ای از این شبکه های موجود، ما نتیجه گرفتیم که تنظیم دقیق مدل های یادگیری عمیق موجود به طور قابل توجهی کارایی مدل را افزایش داده است. پس از تنظیم پارامترهای مدل VGG، این مدل به بهترین حالت خود رسید و با دقت 93.5% بر روی داده های موجود برای تأیید، نشان داد که مدل ما تکنولوژی جدید غالب برای طبقه بندی با دامنه گسترده تری است. در آینده، جمع آوری داده های مربوط به چندین بیماری در همه مراحل می تواند با استفاده از گوناگونی ت سنسورها انجام شود، مانند دوربین های مادون قرمز و دوربین های چندگانه. مدل یادگیری عمیق با پیشنهاد درمان، تأیید نتیجه و غیره اضافه خواهد شد.

## اعلام CRediT contribution to authorship

**Adesh V. Panchal:** ایده پردازی، جمع آوری داده. Subhash Chandra P. Bagyalakshmi: تحلیل فرمایشی، جذب مالی. K. Bagyalakshmi: تحقیق، روش شناسی، مدیریت پروژه. Pankaj Kumar: تجسم، تأیید، منابع، نرم افزار، نظارت. **Ihtiram Raza Khan:** تأیید، تجسم. **Mukesh Soni:** تأیید، تجسم.

نوشتن - نسخه اولیه، نوشتن - بازبینی و ویرایش.

## اعلام Competing Interest

نویسندگان اعلام می کنند که هیچ منافع مالی یا روابط شخصی شناخته شده ای ندارند که ممکن است تأثیرگذار بر کار گزارش شده در این مقاله باشند.

## منابع

- [1] S.R. Sujana و همکاران، شناسایی در زمان واقعی اشیاء با استفاده از شبکه های عصبی کانولوشن عمیق، کنفرانس بین المللی ارتباطات و پردازش سیگنال (ICCSP)، 2017.
- [2] Horea Murea, an, Mihai Oltean, تشخیص میوه از تصاویر با استفاده از یادگیری عمیق، 26-42 (2018) 10 (1) Acta Universitatis Sapientiae Informatica Deep-plant: شناسایی گیاهان با شبکه های عصبی کانولار، کنفرانس بین المللی پردازش تصویر IEEE 2015.
- [3] J.G.A. t. J. باربدو، عوامل مؤثر بر استفاده از یادگیری عمیق برای تشخیص بیماری های گیاهی، Biosyst. مهندس 172 (2018) 8491t.
- [5] [5] تی.جی.جی. Barbedo, Arnal, روشی خودکار برای تشخیص و اندازه گیری علائم بیماری برگ با استفاده از پردازش تصویر دیجیتال، 1709 (2014) 98 (12) Plant Dis.
- [6] [6] H. Al Hiary, S. Beni Ahmad, M. Reyat, M. Braik, Z. AlRahamneh, تشخیص سریع و دقیق و طبقه بندی بیماری های گیاهی، اینتر. J. Comput. Appl. 17n(1) (2011) 3138t.
- [7] [7] یو. مختار، م. ا. علی، ع. ای. حسنین، اح. هفنی، شناسایی دو ویروس برگ گوجه فرنگی با استفاده از ماشین بردار پشتیبان، در طراحی سیستم های اطلاعات و برنامه های هوشمند، ویرایش های K. J. Mandal, S. C. Satapathy, M. K. Sanyal, P. P. دولت، آقای مخوپادهای (اسپرینگر)، 2015.
- [8] [8] t S. Arivazhagan و همکاران، تشخیص منطقه ناسالم برگ گیاه و طبقه بندی بیماری های برگ گیاه با استفاده از ویژگی های بافت، Agri. مهندس اینتر 15 (1) (201) CIGRnJ. 211217t.
- [9] [9] J. Tian و همکاران، یک مدل طبقه بندی بهبود یافته KPCA/GA-SVM برای تشخیص ص بیماری برگ گیاهی، J. Comput. Inf. سیستم 8 (2012) 737745t.
- [10] [10] t. H.M. محمد، م.ت. نوریتوانی، م.س.ب. شاه ریزم، مطالعه مقایسه ای دستگاه بردار پشتیبان مبتنی بر هسته از بیماری مغذی برگ خرما، 13531 (2012) nProcedia Eng. 359t.
- [11] [11] Geoffrey E. Hinton و Ilya Sutskever، طبقه بندی و Imagenet با شبکه های عصبی عمیق کانولار، پیشرفت ها در سیستم های اطلاعات عصبی 2012.
- [12] [12] K.P. Ferentinos و همکاران، مدل های یادگیری عمیق برای تشخیص و تشخیص بیماری های گیاهی، 311-318 (2018) 145 Comput. Electron. Agric.
- [13] [13] B.J. Samajpati, S.D. Degadwala, روش ترکیبی برای تشخیص و طبقه بندی بیماری های میوه سیب با استفاده از طبقه بندی درخت تصادفی، کنفرانس بین المللی ارتباطات و پردازش سیگنال (PSCCI)، 2012.

- [14] B.J. Samajpati, S.D. Degadwala, بررسی ای بر تشخیص و طبقه بندی بیمار ی های میوه سیب، 25-32 (2018) 130 Inter. J. Comput. Appl.
- [15] M.D. Rana, H. Mr. Sheshang, D. Degadwala, روش های مختلف ترکیب تصاویر، 1-13 (2018) 2 (10) JSRD-Inter. J. Sci. Res. Dev.
- [16] Abbas F. Tukiwala, Sheshang D. Degadwala, "مخفی کردن داده در تصویر با اس تعاده از DWT دو بعدی چندین سطح و تبدیل ASCII و تابع ریاضی چرخه ای
- [17] D.H. Rana, S.D. Degadwala, ترکیب تبدیل های چندین رزولوشن و چندین مق یاس برای ترکیب تصاویر پزشکی، 29-26 (2018) 107 Int. J. Comput. Appl.
- [18] P. میلواتان، R. گووینداراج، استخراج ویژگی های بهینه و مدل پیس بینی بیمه پزشکی م بینی بر طبقه بندی یادگیری ماشین با تلفیق اینترنت اشیا، مجله بین المللی کاربردهای کامپیوتر ی، 1-13 (2018) 2 (10) JSRD-Inter. J. Sci. Res. Dev.
- [19] t. D. Babitha, M. Ismail, S. Chowdhury, R. Govindaraj, سیستم نظارت خودکار ایمنی جاده با استفاده از رویکرد ترکیبی cnn-istm، اینتر. J. Adv. Trends Comput. 8 (2020) 17671773t.
- [20] G. Ramya, G. Priya, C. Subrata, D. Kim, D.T. Tran, A.N. [20] لی، رامیا گوویندرج، برر سی کاربردهای مختلف مدیریت اعتماد مبتنی بر شهرت، Inter. جی. اینتر. (Mobile 15 (10) 2021) 87, https://doi.org/10.3991/ijim.
- [21] سوپراتا چودری، کولا بانو پراکاش، اسکی. Nazeer, Pradeep Kumar Vadla, مدل برنامه نوی سی لایه برای تامین منابع در محاسبات مه با استفاده از شبیه ساز مه دیگر، Int. J. Emerg. Res. 8 (9) 2020 4933
- [22] Sudhakar Sengan, N. Satheesh, Ganga Rama Koteswara Rao, Subratan Chowd hury, Kolla Bhanu Prakash, Blockchain - IoT ترتیبات اعتبارسنجی نامحدود، بین المللی. J. Adv. محاسبه گرایس ها 5405-5398 2020 9 علمی مهندس
- [23] [23] Sudhakar Sengan, N. Satheesh, Ganga Rama Koteswara Rao, Subratan Chowd hury, Kolla Bhanu Prakash, Blockchain - IoT ترتیبات اعتبارسنجی نامحدود، بین المللی. J. Adv. محاسبه گرایس ها 5405-5398 2020 9 علمی مهندس
- [24] M. Soni, D. Kumar, طرح واترمارک دیجیتال مبتنی بر موجک برای Medical Images، دوازدهمین کنفرانس بین المللی هوش محاسباتی و شبکه های ارتباطی (ICICN)، هند، 2020، صفحات 403-407. doi: 10.1109/sesn49253.2020.9242626.
- [25] [25] M. Soni, D. Kumar, طرح واترمارک دیجیتال مبتنی بر موجک برای Medical Images، دوازدهمین کنفرانس بین المللی هوش محاسباتی و شبکه های ارتباطی (ICICN)، هند، 2020، صفحات 403-407. doi: 10.1109/sesn49253.2020.9242626.
- [26] [26] M. Soni, D. Kumar, طرح واترمارک دیجیتال مبتنی بر موجک برای Medical Images، دوازدهمین کنفرانس بین المللی هوش محاسباتی و شبکه های ارتباطی (ICICN)، هند، 2020، صفحات 403-407. doi: 10.1109/sesn49253.2020.9242626.
- [27] [27] M. Soni, D. Kumar, طرح واترمارک دیجیتال مبتنی بر موجک برای Medical Images، دوازدهمین کنفرانس بین المللی هوش محاسباتی و شبکه های ارتباطی (ICICN)، هند، 2020، صفحات 403-407. doi: 10.1109/sesn49253.2020.9242626.
- [28] [28] M. Soni, D. Kumar, طرح واترمارک دیجیتال مبتنی بر موجک برای Medical Images، دوازدهمین کنفرانس بین المللی هوش محاسباتی و شبکه های ارتباطی (ICICN)، هند، 2020، صفحات 403-407. doi: 10.1109/sesn49253.2020.9242626.
- [29] [29] M. Soni, D. Kumar, طرح واترمارک دیجیتال مبتنی بر موجک برای Medical Images، دوازدهمین کنفرانس بین المللی هوش محاسباتی و شبکه های ارتباطی (ICICN)، هند، 2020، صفحات 403-407. doi: 10.1109/sesn49253.2020.9242626.
- [30] [30] M. Soni, D. Kumar, طرح واترمارک دیجیتال مبتنی بر موجک برای Medical Images، دوازدهمین کنفرانس بین المللی هوش محاسباتی و شبکه های ارتباطی (ICICN)، هند، 2020، صفحات 403-407. doi: 10.1109/sesn49253.2020.9242626.
- [31] [31] M. Soni, D. Kumar, طرح واترمارک دیجیتال مبتنی بر موجک برای Medical Images، دوازدهمین کنفرانس بین المللی هوش محاسباتی و شبکه های ارتباطی (ICICN)، هند، 2020، صفحات 403-407. doi: 10.1109/sesn49253.2020.9242626.
- [32] [32] M. Soni, D. Kumar, طرح واترمارک دیجیتال مبتنی بر موجک برای Medical Images، دوازدهمین کنفرانس بین المللی هوش محاسباتی و شبکه های ارتباطی (ICICN)، هند، 2020، صفحات 403-407. doi: 10.1109/sesn49253.2020.9242626.
- [33] [33] M. Soni, D. Kumar, طرح واترمارک دیجیتال مبتنی بر موجک برای Medical Images، دوازدهمین کنفرانس بین المللی هوش محاسباتی و شبکه های ارتباطی (ICICN)، هند، 2020، صفحات 403-407. doi: 10.1109/sesn49253.2020.9242626.
- [34] [34] M. Soni, D. Kumar, طرح واترمارک دیجیتال مبتنی بر موجک برای Medical Images، دوازدهمین کنفرانس بین المللی هوش محاسباتی و شبکه های ارتباطی (ICICN)، هند، 2020، صفحات 403-407. doi: 10.1109/sesn49253.2020.9242626.
- [35] [35] M. Soni, D. Kumar, طرح واترمارک دیجیتال مبتنی بر موجک برای Medical Images، دوازدهمین کنفرانس بین المللی هوش محاسباتی و شبکه های ارتباطی (ICICN)، هند، 2020، صفحات 403-407. doi: 10.1109/sesn49253.2020.9242626.
- [36] [36] M. Soni, D. Kumar, طرح واترمارک دیجیتال مبتنی بر موجک برای Medical Images، دوازدهمین کنفرانس بین المللی هوش محاسباتی و شبکه های ارتباطی (ICICN)، هند، 2020، صفحات 403-407. doi: 10.1109/sesn49253.2020.9242626.
- [37] [37] M. Soni, D. Kumar, طرح واترمارک دیجیتال مبتنی بر موجک برای Medical Images، دوازدهمین کنفرانس بین المللی هوش محاسباتی و شبکه های ارتباطی (ICICN)، هند، 2020، صفحات 403-407. doi: 10.1109/sesn49253.2020.9242626.

A.V. Panchal, Subhash Chandra Patel, K. Bagyalakshmi و همکاران.

aterails Today: Proceedings xxx (xxxx) xxxم

[38] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, Z. Wojna, یازاندیشی در معماری اول  
یه برای بینایی کامپیوتر، در مجموعه مقالات کنفرانس IEEE 2016 در مورد دید رایانه و تشخیص  
الگو، CVPR 2016، صفحات 2818-2826، جولای 2016.  
[39] t M. Mehdipour Ghazi, B. Yanikoglu, E. Aptoula, شناسایی گیاه با استفاده از  
شبکه های عصبی عمیق از طریق بهینه سازی پارامترهای یادگیری انتقالی، nNeurocomputin  
g 235 (2017) 228-235t.

[40] S. Hang, M. Aono, شناسایی تصویر گیاهی جهان باز بر اساس شبکه عصب  
ی کانولوشنی، اجلاس و کنفرانس سالانه انجمن APSIPA)، صفحه 14، ججو، کره جنوبی، دسام  
بر 2016. در مجموعه مقالات the2016nAsia. پردازش سیگنال و اطلاعات T-Pacific.